

Análise e Simulação de um Sistema de Filas M/M/1 com Abandono

Ana C. S. Fernandes, Agiana Janira P. M. da Silva, Pedro L. de Oliveira
ana.cecilia@mtel.inatel.br, agiana.silva@mtel.inatel.br, pedro.oliveira@mtel.inatel.br
Santa Rita do Sapucaí, Brasil
Inatel

Resumo—A teoria das filas constitui uma ferramenta amplamente utilizada na modelagem e análise de sistemas de comunicação, atendimento e processamento de serviços. Neste trabalho é apresentado um estudo de caso envolvendo uma fila do tipo M/M/1 com abandono dependente do tempo de espera, cujo objetivo é avaliar o impacto da tolerância dos usuários sobre o desempenho do sistema. O modelo considera chegadas segundo um processo de Poisson, tempos de atendimento exponenciais e um mecanismo de abandono em que cada cliente possui um tempo máximo de espera, também modelado por uma distribuição exponencial. A análise foi conduzida por meio de simulação de eventos discretos implementada na linguagem Python, permitindo representar o comportamento dinâmico do sistema sob diferentes condições operacionais. Foram avaliados múltiplos cenários de tolerância dos clientes e os resultados obtidos foram comparados com aqueles observados em uma fila M/M/1 tradicional. Os experimentos foram realizados utilizando repetições independentes e análise estatística dos indicadores de desempenho. Os resultados indicaram que o aumento da taxa de abandono reduz o congestionamento do sistema, refletindo em menores tempos médios de espera e menores comprimentos médios de fila, embora implique em uma maior proporção de clientes que deixam o sistema sem serem atendidos. Os resultados obtidos evidenciam a importância da consideração do abandono em modelos de filas aplicados a sistemas sujeitos a elevados níveis de carga.

Index Terms—Teoria das Filas, Fila M/M/1, Abandono de Clientes, Simulação de Eventos Discretos, Sistemas de Comunicação.

I. INTRODUÇÃO

A teoria das filas constitui uma importante área da Pesquisa Operacional e da Engenharia de Sistemas, sendo amplamente empregada na modelagem e análise de sistemas nos quais há compartilhamento de recursos limitados entre múltiplos usuários [1], [2], [7]. Aplicações dessa teoria podem ser encontradas em diversos contextos, como redes de computadores, sistemas de telecomunicações, centrais de atendimento, serviços em nuvem e processos industriais [3], [8]. Seu principal objetivo é compreender o comportamento de sistemas sujeitos a demandas aleatórias, permitindo a avaliação de métricas de desempenho relacionadas ao tempo de

espera, utilização dos recursos e qualidade do serviço oferecido.

Dentre os modelos clássicos de filas, destaca-se o sistema M/M/1, caracterizado por um único servidor, chegadas descritas por um processo de Poisson e tempos de atendimento distribuídos exponencialmente [1], [2], [4]. Embora esse modelo forneça uma representação matemática simples e eficiente para diversos cenários, ele assume que todos os clientes permanecem no sistema até serem atendidos, desconsiderando comportamentos frequentemente observados em aplicações reais.

Em muitos sistemas de atendimento, os usuários apresentam uma tolerância limitada ao tempo de espera, podendo desistir do serviço caso a demora exceda um determinado limite. Esse fenômeno, conhecido como abandono da fila ou *reneging*, influencia significativamente o desempenho do sistema [6], afetando tanto a experiência dos usuários quanto a eficiência operacional dos recursos disponíveis. Dessa forma, a incorporação do abandono aos modelos de filas torna-se essencial para uma representação mais fiel de ambientes reais.

Neste contexto, o presente trabalho analisa um sistema M/M/1 com abandono dependente do tempo de espera. Nesse modelo, cada cliente possui um tempo máximo de permanência na fila, representado por uma variável aleatória com distribuição exponencial. Caso o tempo de espera ultrapasse esse limite, o cliente abandona o sistema antes de receber atendimento. A adoção dessa abordagem permite investigar os impactos da impaciência dos usuários sobre indicadores de desempenho, tais como o comprimento médio da fila, o tempo médio de permanência no sistema, a taxa de abandono e a utilização do servidor.

Por meio de simulação de eventos discretos, busca-se avaliar como os parâmetros de chegada, atendimento e tolerância dos clientes influenciam a dinâmica do sistema [9], [10], fornecendo subsídios para o dimensionamento e a otimização de serviços em que o abandono representa um fator relevante para a qualidade do atendimento e para a eficiência operacional.

II. MODELAGEM DO SISTEMA

A Figura 1 apresenta o diagrama de estados da fila M/M/1 clássica, utilizada como base para o desenvolvimento do modelo estudado. Cada estado representa o número de clientes presentes no sistema, enquanto as transições entre estados são governadas pelas taxas de chegada λ e de atendimento μ . O modelo proposto neste trabalho estende essa estrutura ao incorporar um mecanismo de abandono dependente do tempo de espera, permitindo que clientes deixem a fila antes de serem atendidos.

Fila M/M/1 – Diagrama de Estado




Figura 1: Diagrama de estados da fila M/M/1 utilizada como base para a modelagem do sistema.

O sistema estudado corresponde a uma fila do tipo M/M/1 com abandono dependente do tempo de espera. Considera-se um sistema de atendimento remoto composto por uma única fila e um único servidor. Os clientes chegam ao sistema segundo um processo de Poisson com taxa média λ , enquanto os tempos de atendimento seguem uma distribuição exponencial com taxa μ .

Diferentemente da fila M/M/1 clássica, na qual os clientes aguardam até serem atendidos, o modelo proposto considera que cada cliente possui uma tolerância máxima de espera. Essa tolerância é representada por uma variável aleatória (T), com distribuição exponencial de parâmetro θ . Caso o cliente permaneça na fila por um tempo superior a (T), ele abandona o sistema sem receber atendimento.

A simulação será realizada por eventos discretos, considerando a evolução temporal do sistema a partir da ocorrência de eventos de chegada, início de atendimento, término de atendimento e abandono. Essa abordagem está de acordo com a proposta do estudo de caso, que solicita a definição das variáveis de estado, entidades e eventos do sistema.

A. Variáveis de Estado

As principais variáveis de estado do sistema são:

Tabela I: Variáveis de estado do sistema

Variável	Descrição
$N(t)$	Número de clientes no sistema.
$Q(t)$	Número de clientes na fila.
$S(t)$	Estado do servidor (0 = livre, 1 = ocupado).

A variável $N(t)$ representa a população total presente no sistema, incluindo clientes em atendimento e clientes aguardando na fila. A variável $Q(t)$ representa exclusivamente os clientes que se encontram em espera. Já a variável $S(t)$ descreve a condição operacional do servidor.

B. Entidades do Sistema

As entidades consideradas no modelo são apresentadas na tabela abaixo:

Tabela II: Entidades do sistema

Entidade	Descrição
Cliente	Usuário que chega ao sistema para solicitar atendimento.
Servidor	Recurso responsável pela execução do atendimento.
Fila	Estrutura onde os clientes aguardam a disponibilidade do servidor.

Atributos da Entidade Cliente

Cada cliente é caracterizado pelos seguintes atributos:

Tabela III: Atributos da entidade cliente

Atributo	Descrição
Instante de chegada	Momento em que o cliente ingressa no sistema.
Tempo de tolerância (T)	Tempo máximo que o cliente aceita aguardar na fila.
Instante de abandono	Momento em que o cliente abandonará a fila caso não seja atendido.

C. Eventos do Sistema

A evolução do sistema ocorre por meio da ocorrência de eventos discretos.

Tabela IV: Eventos do sistema

Evento	Descrição
Chegada	Entrada de um novo cliente no sistema.
Término do atendimento	Conclusão do serviço prestado a um cliente.
Abandono	Saída de um cliente da fila devido ao esgotamento de sua tolerância de espera.

O início do atendimento não é tratado como um evento independente, pois ocorre imediatamente após uma chegada ou após o término de um atendimento quando existe pelo menos um cliente aguardando na fila.

D. Hipóteses do Modelo

Para a modelagem do sistema foram adotadas as seguintes hipóteses:

- 1) As chegadas seguem um processo de Poisson com taxa λ ;

- 2) Os tempos de atendimento seguem distribuição exponencial com taxa μ ;
- 3) O sistema possui um único servidor;
- 4) A capacidade da fila é considerada ilimitada;
- 5) A disciplina de atendimento é FIFO;
- 6) O tempo máximo de tolerância dos clientes segue distribuição exponencial com taxa θ ;
- 7) Clientes em atendimento não abandonam o sistema;
- 8) Todos os processos aleatórios são mutuamente independentes.

III. METODOLOGIA DE SIMULAÇÃO

A avaliação do sistema foi realizada por meio da técnica de simulação de eventos discretos, implementada na linguagem Python. Essa abordagem permite representar a evolução temporal da fila a partir da ocorrência de eventos que modificam o estado do sistema, como chegadas, atendimentos e abandonos.

Inicialmente, o sistema é considerado vazio, com o servidor livre e sem clientes na fila. Os instantes de chegada são gerados segundo um processo de Poisson com taxa λ , enquanto os tempos de atendimento seguem uma distribuição exponencial com taxa μ . O tempo máximo de tolerância dos clientes também é modelado por uma distribuição exponencial com parâmetro θ .

Durante a execução da simulação, são monitorados três eventos principais: chegada de clientes, término de atendimento e abandono da fila. A cada ocorrência, o estado do sistema é atualizado e as estatísticas de desempenho são registradas.

A Figura 2 apresenta a estrutura geral da simulação desenvolvida.




Figura 2: Estrutura Geral da Simulação

Com o objetivo de avaliar o impacto da tolerância dos clientes sobre o desempenho do sistema, foram considerados diferentes cenários experimentais. Em cada cenário, foram realizadas 30 repetições independentes e os resultados foram analisados por meio de intervalos de confiança de 95%.

Parâmetros Experimentais

Tabela V: Parâmetros da simulação

Parâmetro	Valor
Taxa de chegada (λ)	4 clientes/unidade de tempo.
Taxa de atendimento (μ)	5 clientes/unidade de tempo.
Taxa de abandono (θ)	0; 0,1; 0,5; 1,0.
Horizonte de simulação	10.000 unidades de tempo.
Número de repetições	30.
Nível de confiança	95%.

As métricas coletadas durante a simulação incluem o número médio de clientes no sistema, o número médio de clientes na fila, o tempo médio de espera, o tempo médio de permanência, a utilização do servidor e a taxa de abandono.


IV. IMPLEMENTAÇÃO COMPUTACIONAL E RESULTADOS

O sistema estudado foi modelado como uma fila M/M/1 com abandono dependente do tempo de espera. Na notação de Kendall, o primeiro termo M indica que os intervalos entre chegadas seguem distribuição exponencial, associada a um processo de Poisson com taxa média λ . O segundo termo M indica que os tempos de serviço seguem distribuição exponencial com taxa média μ . O termo 1 representa a existência de um único servidor responsável pelo atendimento dos clientes [1], [2], [7].


O diferencial do modelo proposto é a inclusão de abandono. Cada cliente possui uma tolerância máxima de espera T , modelada por uma variável aleatória exponencial com taxa θ . Assim, a tolerância média é dada por $E[T] = 1/\theta$. Caso o cliente permaneça na fila por um tempo superior à sua tolerância, ele abandona o sistema sem receber atendimento. Esse comportamento é relevante em sistemas de suporte, atendimento remoto, centrais telefônicas e serviços digitais, nos quais usuários podem desistir antes de serem atendidos [2], [8].

A implementação computacional foi realizada por simulação de eventos discretos, abordagem adequada para sistemas em que as mudanças de estado ocorrem apenas em instantes específicos, como chegadas, termos de atendimento e abandonos [9], [10]. Antes da execução da simulação, todas as amostras aleatórias foram geradas, incluindo tempos de chegada, tempos de serviço e tolerâncias individuais. Essa decisão aumenta a reprodutibilidade dos resultados e permite comparar cenários sob condições controladas.

Durante a simulação, cada cliente é representado por uma estrutura contendo identificador, instante de chegada, tempo de serviço, tolerância, limite de abandono, instante de início de atendimento, instante de saída e estado final. Os possíveis estados são: em fila, em atendimento, atendido ou abandonado. O simulador processa três eventos principais: chegada de cliente, término de atendimento e abandono. Essa estrutura segue a lógica



(a) Fluxograma do evento de chegada da fila M/M/1 com abandono.



(b) Fluxograma dos eventos de saída e abandono.

Figura 3: Fluxogramas dos principais eventos da simulação.

clássica de simulação de eventos discretos aplicada a sistemas de filas [9], [10].

A. Parâmetros e Métricas da Simulação

A simulação base utilizou 5000 clientes, taxa de chegada $\lambda = 0,9$, taxa de serviço $\mu = 1,0$ e taxa de abandono $\theta = 0,2$. Com esses parâmetros, o fator de carga teórico $\rho = \lambda/\mu$ é igual a 0,9.

Tabela VI: Parâmetros utilizados na simulação base.

Parâmetro	Valor
Número de clientes simulados	5000,000
Taxa de chegada λ	0,900
Taxa de serviço μ	1,000
Taxa de abandono θ	0,200
Fator de carga teórico $\rho = \lambda/\mu$	0,900

As métricas avaliadas incluem clientes atendidos, clientes abandonados, taxa de atendimento, taxa de abandono, throughput, utilização do servidor, número médio na fila L_q , número médio no sistema L , tempo médio de espera, tempo médio no sistema, tempo médio até abandono, espera máxima, desvio padrão da espera e percentil 95 da espera. Essas métricas são amplamente utilizadas na análise de desempenho de sistemas de filas [1], [2].

B. Resultados da Simulação Base

A Tabela VII apresenta os resultados obtidos para a simulação base. Observa-se que, dos 5000 clientes simulados, 3945 foram atendidos e 1055 abandonaram o sistema antes de iniciar atendimento. Isso corresponde a uma taxa de abandono de 21,10%.

Tabela VII: Resultados da simulação base da fila M/M/1 com abandono.

Métrica	Valor
Clientes atendidos	3945,000
Clientes abandonaram	1055,000
Taxa de atendimento	0,789
Taxa de abandono	0,211
Throughput	0,709
Utilização do servidor	0,711
Número médio na fila L_q	0,958
Número médio no sistema L	1,668
Tempo médio de espera dos atendidos	1,014
Tempo médio no sistema dos atendidos	2,017
Tempo médio até abandono	1,257
Espera máxima dos atendidos	7,770
Desvio padrão da espera	1,296
Percentil 95 da espera	3,746

Os resultados indicam que o sistema opera com utilização média de aproximadamente 71,1%. Embora o fator de carga teórico ρ seja 0,9, a utilização efetiva observada é menor porque parte dos clientes abandona a fila antes de receber atendimento. Esse comportamento é esperado em sistemas com abandono, pois a demanda efetiva atendida pelo servidor é menor que a demanda originalmente gerada [?], [?].

A Figura 4 apresenta a evolução acumulada dos clientes atendidos e dos clientes que abandonaram o sistema ao longo da simulação. Observa-se que ambas as curvas crescem continuamente, porém a quantidade de atendimentos permanece significativamente superior à quantidade de abandonos. Esse comportamento indica que o servidor consegue atender a maior parte da demanda,

embora exista uma parcela relevante de clientes que deixa a fila antes do início do atendimento, evidenciando o impacto da tolerância máxima de espera no desempenho do sistema.




Figura 4: Clientes atendidos e abandonos acumulados ao longo do tempo.

Já a Figura 5 apresenta a evolução da utilização acumulada do servidor ao longo da simulação. Observa-se uma maior variabilidade nos instantes iniciais, resultado do número de eventos processados nesse momento inicial. À medida que a simulação avança, a curva converge para um valor aproximadamente constante em torno de 71%, indicando a estabilização do sistema em regime permanente.

Esse resultado é coerente com os indicadores obtidos na Tabela VII, na qual a utilização média observada foi de 71,1%. Nota-se ainda que a utilização efetiva do servidor é inferior ao fator de carga teórico $\rho = 0,9$, uma vez que parte dos clientes abandona a fila antes de ser atendida. Dessa forma, embora a demanda potencial corresponda a 90% da capacidade do servidor, a carga efetivamente processada é reduzida pelos abandonos, diminuindo a ocupação média do recurso ao longo da simulação.




Figura 5: Utilização acumulada do servidor na simulação base.

Por fim, a Figura 6 apresenta a distribuição dos tempos de espera dos clientes que efetivamente receberam atendimento. Observa-se uma forte concentração de ocorrências próximas de zero, indicando que uma parcela significativa dos clientes foi atendida rapidamente após sua chegada ao sistema. À medida que o tempo de espera aumenta, a frequência de observações diminui gradualmente, formando uma cauda longa característica de sistemas de filas com chegadas e tempos de serviço aleatórios.

Esse comportamento evidencia que, embora a maioria dos clientes experimente tempos de espera reduzidos, existe uma parcela menor sujeita a períodos de espera significativamente mais elevados. Tal resultado é confirmado pelas estatísticas apresentadas na Tabela VII, que indicam tempo médio de espera de aproximadamente 1,01 unidade de tempo, desvio padrão de 1,30 e percentil 95 de 3,75 unidades de tempo. Isso significa que 95% dos clientes atendidos aguardaram menos de 3,75 unidades de tempo, enquanto apenas uma pequena fração experimentou tempos de espera mais elevados.

A presença dessa assimetria é compatível com o comportamento esperado em filas M/M/1, nas quais a variabilidade inerente aos processos de chegada e atendimento pode ocasionar períodos temporários de congestionamento. No modelo proposto, o mecanismo de abandono também contribui para limitar o crescimento excessivo da fila, reduzindo a quantidade de clientes submetidos a tempos de espera extremamente longos. Como consequência, a distribuição observada apresenta elevada concentração em tempos reduzidos e uma cauda relativamente controlada quando comparada a sistemas equivalentes sem abandono.




Figura 6: Histograma do tempo de espera dos clientes atendidos.

C. Avaliação Paramétrica

1) *Impacto da Taxa de Chegada:* O primeiro experimento avaliou o impacto da taxa de chegada λ , mantendo $\mu = 1,0$ e $\theta = 0,2$. A Tabela VIII mostra os resultados obtidos.

Tabela VIII: Impacto da taxa de chegada λ sobre o desempenho da fila.

λ	ρ	Atend.	Aband.	Aband.(%)	W_q	L_q	Vaz.
0.2	0.2	4827	173	3.46	0.148	0.034	0.193
0.4	0.4	4623	377	7.54	0.326	0.150	0.369
0.6	0.6	4380	620	12.40	0.549	0.368	0.525
0.8	0.8	4102	898	17.96	0.848	0.728	0.655
1.0	1.0	3796	1204	24.08	1.158	1.197	0.758
1.2	1.2	3503	1497	29.94	1.518	1.809	0.839

Onde λ representa a taxa média de chegada de clientes ao sistema, ρ a intensidade de tráfego, W_q o tempo médio de espera na fila, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados.

O aumento de λ provoca crescimento da carga oferecida ao sistema. Como consequência, observa-se aumento do tempo médio de espera, do número médio na fila e da taxa de abandono como visto nas figuras a seguir. Esse comportamento é coerente com a teoria de filas, segundo a qual sistemas com maior intensidade de chegada tendem a apresentar maior congestionamento quando a capacidade de serviço permanece constante [1], [7].




Figura 7: Tempo médio de espera em função da taxa de chegada λ .




Figura 8: Taxa de abandono em função da taxa de chegada λ .




Figura 9: Número médio na fila L_q em função da taxa de chegada λ .

2) *Impacto da Taxa de Abandono:* O segundo experimento avaliou o impacto da taxa de abandono θ , mantendo $\lambda = 0,9$ e $\mu = 1,0$. A Tabela IX apresenta os resultados.

Tabela IX: Impacto da taxa de abandono θ sobre o desempenho da fila.

θ	$1/\theta$	Atend.	Aband.	Aband.(%)	W_q	L_q	Vaz.
0.01	100.0	4780	220	4.40	4.690	4.209	0.859
0.05	20.0	4409	591	11.82	2.381	2.172	0.793
0.10	10.0	4203	797	15.94	1.580	1.449	0.756
0.20	5.0	3945	1055	21.10	1.014	0.958	0.709
0.50	2.0	3580	1420	28.40	0.479	0.513	0.644
1.00	1.0	3281	1719	34.38	0.230	0.305	0.590

Onde θ representa a taxa de abandono, $1/\theta$ o tempo médio de tolerância dos clientes, W_q o tempo médio de espera na fila, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados. Onde W_q representa o tempo médio de espera na fila, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados.

Os resultados mostram que o aumento de θ eleva a taxa de abandono, pois reduz a tolerância média dos clientes. Ao mesmo tempo, o tempo médio de espera dos clientes atendidos diminui. Essa redução, contudo, não deve ser interpretada isoladamente como melhoria operacional, pois ocorre em conjunto com maior perda de clientes. Esse efeito é característico de sistemas com abandono, nos quais a fila pode diminuir não porque o atendimento melhorou, mas porque parte da demanda foi perdida [2], [8].




Figura 10: Taxa de abandono em função da taxa de abandono θ .




Figura 11: Tempo médio de espera em função da taxa de abandono θ .




Figura 12: Número médio na fila L_q em função da taxa de abandono θ .




Figura 14: Taxa de abandono em função da taxa de serviço μ .

3) *Impacto da Taxa de Serviço:* O terceiro experimento avaliou o impacto da taxa de serviço μ , mantendo $\lambda = 0,9$ e $\theta = 0,2$. A Tabela X apresenta os resultados.

Tabela X: Impacto da taxa de serviço μ sobre o desempenho da fila.

μ	ρ	Atend.	Aband.	Aband.(%)	W_q	L_q	Vaz.
0.6	1.500	2974	2026	40.52	2.060	1.817	0.535
0.8	1.125	3540	1460	29.20	1.467	1.340	0.636
1.0	0.900	3945	1055	21.10	1.014	0.958	0.709
1.2	0.750	4248	752	15.04	0.701	0.676	0.764
1.5	0.600	4492	508	10.16	0.451	0.440	0.807

O aumento de μ reduz o tempo médio de espera, o número médio na fila e a taxa de abandono. Esse resultado evidencia que o aumento da capacidade de serviço atua diretamente sobre a causa do congestionamento. Diferentemente do abandono, que reduz a fila por perda de clientes, o aumento de μ reduz a espera preservando maior proporção de atendimentos [1], [2].




Figura 13: Tempo médio de espera em função da taxa de serviço μ .




Figura 15: Utilização do servidor em função da taxa de serviço μ .

V. COMPARAÇÃO COM MODELOS CLÁSSICOS

Para avaliar o desempenho relativo da fila proposta, foram realizadas comparações com três modelos clássicos: M/M/1 sem abandono, M/D/1 sem abandono e M/M/2 sem abandono. Esses modelos permitem comparar, respectivamente, o efeito do abandono, da redução da variabilidade do serviço e do aumento da capacidade de atendimento [2], [7].

Tabela XI: Comparação geral entre a fila proposta e modelos clássicos.

Modelo	Atend.	Aband.	Aband.(%)	W_q	L_q	Vaz.
M/M/1(com)	3945	1055	21.10	1.014	0.958	0.709
M/M/1(sem)	5000	0	0.00	7.979	7.171	0.899
M/D/1(sem)	5000	0	0.00	4.673	4.199	0.899
M/M/2(sem)	5000	0	0.00	0.272	0.245	0.899

Onde W_q representa o tempo médio de espera na fila, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados.

A. Comparação com M/M/1 Sem Abandono

Tabela XII: Comparação entre M/M/1 com abandono e M/M/1 sem abandono.

Modelo	Atend.	Aband.	Aband.(%)	W_q	W	L_q	Vaz.
M/M/1(com)	3945	1055	21.10	1.014	2.017	0.958	0.709
M/M/1(sem)	5000	0	0.00	7.979	8.977	7.171	0.899

Onde W_q representa o tempo médio de espera na fila, W o tempo médio no sistema, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados. A comparação mostra que o abandono reduz fortemente a espera média e o número médio na fila. Entretanto, essa melhoria aparente ocorre porque 21,10% dos clientes deixam o sistema antes do atendimento. Assim, a redução de L_q e da espera média deve ser interpretada como efeito combinado de atendimento e perda de demanda.

B. Comparação com M/D/1 Sem Abandono

Tabela XIII: Comparação entre M/M/1 com abandono e M/D/1 sem abandono.

Modelo	Atend.	Aband.	Aband.(%)	W_q	W	L_q	Vaz.
M/M/1(com)	3945	1055	21.10	1.014	2.017	0.958	0.709
M/D/1(sem)	5000	0	0.00	4.673	5.673	4.199	0.899

Onde W_q representa o tempo médio de espera na fila, W o tempo médio no sistema, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados. O modelo M/D/1 reduz a variabilidade dos tempos de serviço, pois todos os atendimentos possuem duração constante. A literatura mostra que a redução da variabilidade tende a diminuir tempos médios de espera e oscilações na fila [2], [7]. Ainda assim, no experimento realizado, a fila com abandono apresenta menor espera média e menor L_q , mas ao custo de perda de clientes.

C. Comparação com M/M/2 Sem Abandono

Tabela XIV: Comparação entre M/M/1 com abandono e M/M/2 sem abandono.

Modelo	Atend.	Aband.	Aband.(%)	W_q	W	L_q	Vaz.
M/M/1(com)	3945	1055	21.10	1.014	2.017	0.958	0.709
M/M/2(sem)	5000	0	0.00	0.272	1.270	0.245	0.899

Onde W_q representa o tempo médio de espera na fila, W o tempo médio no sistema, L_q o número médio de clientes na fila e a Vazão (Throughput) a taxa efetiva de atendimentos realizados. A comparação com M/M/2 evidencia que o aumento da capacidade de atendimento é mais eficiente do ponto de vista operacional. O modelo M/M/2 apresenta menor espera média, menor L_q , menor L e maior throughput, sem perda de clientes. Logo, enquanto o abandono reduz a fila por desistência, o aumento do número de servidores reduz o congestionamento por ampliação real da capacidade de serviço.

VI. SÍNTESE DOS RESULTADOS

Os experimentos demonstraram que a fila M/M/1 com abandono representa adequadamente sistemas em

que usuários podem desistir antes do atendimento. A variação de λ mostrou que o aumento da demanda eleva espera, congestionamento e abandono. A variação de θ evidenciou que clientes mais impacientes reduzem artificialmente a fila, mas aumentam a perda de demanda. A variação de μ mostrou que o aumento da taxa de serviço reduz espera, fila e abandono de forma mais consistente.

A comparação com modelos clássicos reforça essa conclusão. O abandono pode reduzir métricas aparentes de congestionamento, como espera média e L_q , mas implica perda de clientes. Em contraste, o modelo M/M/2 reduz a espera por aumento real da capacidade de atendimento. Portanto, a análise de sistemas com abandono não deve considerar apenas a redução da fila, mas também a taxa de perda, o throughput e a qualidade efetiva do serviço.

VII. CONCLUSÃO

Este trabalho apresentou a modelagem e a simulação de um sistema de filas do tipo M/M/1 com abandono dependente do tempo de espera, utilizando a técnica de simulação de eventos discretos. A inclusão do mecanismo de abandono permitiu representar de forma mais realista situações em que os usuários possuem tolerância limitada para aguardar atendimento.

Os resultados obtidos evidenciaram que o comportamento do sistema é fortemente influenciado pelas taxas de chegada, atendimento e abandono. Observou-se que o aumento da demanda tende a elevar o congestionamento e os tempos de espera, enquanto o aumento da capacidade de atendimento contribui para a redução desses indicadores. Verificou-se ainda que o abandono pode reduzir o comprimento médio da fila e o tempo médio de espera, porém essa redução ocorre em conjunto com a perda de clientes que deixam o sistema sem receber atendimento.

A comparação com modelos clássicos demonstrou que a simples redução da fila nem sempre representa uma melhoria efetiva do desempenho, uma vez que parte da demanda pode estar sendo perdida. Nesse contexto, a análise conjunta de métricas como tempo de espera, utilização do servidor, throughput e taxa de abandono mostrou-se fundamental para uma avaliação mais completa do sistema.

Dessa forma, conclui-se que a consideração do abandono é essencial para a modelagem de sistemas de atendimento sujeitos à impaciência dos usuários, contribuindo para análises mais realistas e para o planejamento de estratégias que conciliem eficiência operacional e qualidade de serviço.

REFERÊNCIAS

- [1] KLEINROCK, L. **Queueing Systems: Theory**. New York: Wiley-Interscience, 1975. v. 1.
- [2] GROSS, D.; SHORTLE, J. F.; THOMPSON, J. M.; HARRIS, C. M. **Fundamentals of Queueing Theory**. 5. ed. Hoboken: John Wiley & Sons, 2018.
- [3] ALLEN, A. O. **Probability, Statistics and Queueing Theory with Computer Science Applications**. 2. ed. San Diego: Academic Press, 1990.
- [4] MEDHI, J. **Stochastic Models in Queueing Theory**. 2. ed. San Diego: Academic Press, 2003.
- [5] BHAT, U. N. **An Introduction to Queueing Theory: Modeling and Analysis in Applications**. Boston: Birkhäuser, 2008.
- [6] ANCKER, C. J.; GAFARIAN, A. V. Some Queueing Problems with Balking and Reneging-I. *Operations Research*, v. 11, n. 1, p. 88–100, 1963.
- [7] COOPER, R. B. **Introduction to Queueing Theory**. 2. ed. New York: North-Holland, 1981.
- [8] BOLCH, G.; GREINER, S.; DE MEER, H.; TRIVEDI, K. S. **Queueing Networks and Markov Chains: Modeling and Performance Evaluation with Computer Science Applications**. 2. ed. Hoboken: John Wiley & Sons, 2006.
- [9] LAW, A. M. **Simulation Modeling and Analysis**. 5. ed. New York: McGraw-Hill Education, 2015.
- [10] BANKS, J.; CARSON, J. S.; NELSON, B. L.; NICOL, D. M. **Discrete-Event System Simulation**. 5. ed. Upper Saddle River: Prentice Hall, 2010.